

LAPORAN TUGAS AKHIR SEMESTER
PREDIKSI HARGA LAPTOP MENGGUNAKAN SVR DAN KNN

Dosen Pengampu : Andi Hendra, Ph.d



Disusun Oleh :
Moh Maulana Yahya
F55123037

PRODI S1 TEKNIK INFORMATIKA
JURUSAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS TADULAKO
TAHUN
2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi menyebabkan kebutuhan terhadap perangkat laptop semakin meningkat. Laptop digunakan dalam berbagai bidang seperti pendidikan, pekerjaan, bisnis, maupun hiburan. Banyaknya variasi spesifikasi laptop menyebabkan harga laptop menjadi sangat beragam.

Menentukan harga laptop berdasarkan spesifikasinya merupakan permasalahan yang dapat diselesaikan menggunakan teknik Machine Learning. Dengan memanfaatkan data historis spesifikasi dan harga laptop, model machine learning dapat mempelajari pola hubungan antara fitur-fitur perangkat keras dengan harga jual laptop.

Pada penelitian ini digunakan dua metode regresi, yaitu Support Vector Regression (SVR) dan K-Nearest Neighbor Regression (KNN). Kedua metode dipilih karena memiliki karakteristik yang berbeda dalam mempelajari hubungan antar variabel. Hasil prediksi kedua model kemudian dibandingkan menggunakan beberapa metrik evaluasi untuk menentukan model yang memiliki performa terbaik.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah disebutkan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana menerapkan metode Support Vector Regression (SVR) untuk memprediksi harga laptop?
2. Bagaimana menerapkan metode K-Nearest Neighbor Regression (KNN) untuk memprediksi harga laptop?
3. Bagaimana membandingkan performa kedua model menggunakan metrik evaluasi regresi?
4. Fitur apa yang paling berpengaruh terhadap harga laptop?

1.3 Tujuan

Tujuan dari penelitian ini adalah sebagai berikut:

1. Membangun model prediksi harga laptop menggunakan SVR.
2. Membangun model prediksi harga laptop menggunakan KNN.
3. Membandingkan performa kedua model menggunakan nilai MAE, RMSE, dan R^2 .
4. Menentukan fitur yang paling berpengaruh terhadap harga laptop menggunakan Permutation Importance.

BAB II

TEORI DASAR

2.1 Machine Learning

Machine Learning merupakan salah satu cabang dari bidang Artificial Intelligence yang berfokus pada pengembangan algoritma dan model yang memungkinkan komputer belajar dari data tanpa harus diprogram secara eksplisit untuk setiap tugas yang dikerjakan. Dengan memanfaatkan data historis, sistem machine learning dapat mengenali pola, membuat prediksi, serta mengambil keputusan secara otomatis.

Konsep utama machine learning adalah memberikan kemampuan kepada komputer untuk meningkatkan kinerjanya berdasarkan pengalaman atau data yang diterima. Semakin banyak dan semakin baik kualitas data yang digunakan, maka semakin baik pula kemampuan model dalam melakukan prediksi atau klasifikasi.

Machine learning banyak digunakan dalam berbagai bidang, seperti prediksi harga, pengenalan wajah, sistem rekomendasi, analisis sentimen, diagnosis medis, hingga kendaraan otonom.

2.2 Regresi

Regresi merupakan salah satu metode dalam machine learning dan statistika yang digunakan untuk mempelajari hubungan antara variabel independen (*independent variable* atau *feature*) dengan variabel dependen (*dependent variable* atau *target*). Tujuan utama regresi adalah memprediksi nilai numerik atau kontinu berdasarkan pola yang ditemukan dalam data.

Berbeda dengan klasifikasi yang menghasilkan keluaran berupa kategori tertentu, regresi menghasilkan keluaran berupa nilai angka. Oleh karena itu, regresi banyak digunakan untuk memprediksi berbagai fenomena yang memiliki nilai kontinu, seperti harga rumah, harga laptop, jumlah penjualan, curah hujan, dan suhu udara.

Dalam machine learning, model regresi berusaha menemukan fungsi matematis yang dapat menggambarkan hubungan antara variabel input dan output sehingga dapat digunakan untuk melakukan prediksi pada data baru.

2.3 Support Vector Regression (SVR)

Support Vector Regression (SVR) merupakan salah satu algoritma regresi yang dikembangkan dari metode Support Vector Machine (SVM). Jika SVM digunakan untuk permasalahan klasifikasi, maka SVR digunakan untuk menyelesaikan permasalahan prediksi nilai kontinu atau regresi.

SVR bekerja dengan mencari fungsi regresi terbaik yang mampu memprediksi nilai target dengan tingkat kesalahan yang seminimal mungkin. Berbeda dengan metode regresi

konvensional yang berusaha meminimalkan seluruh kesalahan prediksi, SVR memperkenalkan konsep *margin toleransi* yang disebut epsilon (ϵ). Kesalahan yang masih berada dalam batas epsilon dianggap dapat diterima dan tidak dikenakan penalti.

Karena kemampuannya dalam menangani hubungan linear maupun non-linear, SVR banyak digunakan dalam berbagai bidang seperti prediksi harga, peramalan penjualan, prediksi cuaca, dan analisis data finansial.

2.4 K-Nearest Neighbor (KNN)

K-Nearest Neighbor Regression (KNN) merupakan salah satu algoritma machine learning yang digunakan untuk menyelesaikan permasalahan regresi atau prediksi nilai numerik. Algoritma ini merupakan pengembangan dari metode K-Nearest Neighbor (KNN) yang awalnya banyak digunakan untuk klasifikasi.

KNN Regression bekerja berdasarkan prinsip kemiripan data. Ketika terdapat data baru yang akan diprediksi, algoritma akan mencari sejumlah data terdekat dari data tersebut pada dataset pelatihan. Nilai prediksi kemudian diperoleh berdasarkan rata-rata nilai target dari tetangga terdekat yang ditemukan.

Karena menggunakan konsep kedekatan antar data, KNN Regression termasuk algoritma *instance-based learning* atau *lazy learning*, yaitu algoritma yang tidak membangun model secara eksplisit selama proses pelatihan, melainkan melakukan perhitungan saat proses prediksi berlangsung.

2.5 Preprocessing Data

Data Preprocessing merupakan tahap awal dalam proses machine learning yang bertujuan untuk mempersiapkan data agar dapat digunakan secara optimal oleh algoritma pembelajaran mesin. Data yang diperoleh dari berbagai sumber sering kali masih mengandung nilai yang hilang (*missing values*), data duplikat, format yang tidak konsisten, maupun atribut yang tidak sesuai dengan kebutuhan model.

Proses preprocessing dilakukan untuk meningkatkan kualitas data sehingga model machine learning dapat mempelajari pola data dengan lebih baik dan menghasilkan prediksi yang lebih akurat. Tahapan ini menjadi salah satu faktor penting yang menentukan keberhasilan suatu model karena kualitas data yang baik akan menghasilkan performa model yang lebih baik pula.

Dalam implementasi studi kasus, data preprocessing yang digunakan meliputi pengkodean data kategorikal (*encoding*), serta normalisasi atau standarisasi data (*feature scaling*).

2.6 Pembagian Data

Dalam machine learning, dataset yang digunakan untuk membangun model umumnya dibagi menjadi dua bagian utama, yaitu data training dan data testing. Pembagian data ini bertujuan untuk mengukur kemampuan model dalam mempelajari pola dari data serta mengevaluasi kemampuannya dalam melakukan prediksi terhadap data yang belum pernah dilihat sebelumnya.

Jika seluruh data digunakan untuk melatih model tanpa menyisakan data untuk pengujian, maka performa model tidak dapat dievaluasi secara objektif. Model mungkin terlihat memiliki hasil yang sangat baik pada data yang digunakan saat pelatihan, tetapi belum tentu mampu memberikan prediksi yang baik pada data baru. Oleh karena itu, pembagian data menjadi data training dan data testing merupakan langkah penting dalam proses pengembangan model machine learning.

2.7 Hyperparameter Tuning

Hyperparameter Tuning merupakan proses pencarian kombinasi parameter terbaik pada suatu algoritma machine learning untuk memperoleh performa model yang optimal. Hyperparameter adalah parameter yang nilainya ditentukan sebelum proses pelatihan model dimulai dan tidak dipelajari secara otomatis dari data.

Setiap algoritma machine learning memiliki hyperparameter yang dapat memengaruhi kualitas prediksi yang dihasilkan. Oleh karena itu, diperlukan proses optimasi untuk menemukan kombinasi hyperparameter yang menghasilkan performa terbaik.

Dalam penelitian ini, proses hyperparameter tuning dilakukan pada algoritma Support Vector Regression dan K-Nearest Neighbor Regression menggunakan metode Grid Search Cross Validation.

2.8 Evaluasi Model

Evaluasi model merupakan proses pengukuran kinerja suatu model machine learning untuk mengetahui seberapa baik model tersebut dalam melakukan prediksi terhadap data yang belum pernah dilihat sebelumnya. Evaluasi dilakukan setelah proses pelatihan model selesai dengan cara membandingkan nilai hasil prediksi dengan nilai aktual pada data pengujian (*testing data*).

Tujuan utama evaluasi model adalah untuk mengetahui tingkat akurasi prediksi, mengidentifikasi kesalahan model, serta menentukan model yang memiliki performa terbaik. Pada penelitian prediksi harga laptop menggunakan algoritma Support Vector Regression dan K-Nearest Neighbor Regression, evaluasi model dilakukan menggunakan beberapa metrik regresi, yaitu MAE, RMSE, dan R^2 Score.

BAB III

LANGKAH KERJA

3.1 Impor Pustaka

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.model_selection import GridSearchCV

from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import StandardScaler

from sklearn.svm import SVR
from sklearn.neighbors import KNeighborsRegressor
from sklearn.linear_model import LinearRegression

from sklearn.metrics import (
    mean_absolute_error,
    mean_squared_error,
    r2_score
)

from sklearn.inspection import permutation_importance
```

Library atau biasa disebut dengan Pustaka merupakan kumpulan fungsi, kelas, dan modul yang telah disediakan untuk membantu pengembangan suatu program spesifik. Dalam percobaan ini, pustaka-pustaka yang ada pada gambar digunakan untuk beberapa keperluan seperti “numpy” yang berfungsi untuk membantu dalam perhitungan program, dan “sklearn” yang menyediakan format algoritma, beserta beberapa format untuk membantu dalam preprocessing data.

3.2 Load Dataset beserta EDA

```
# =====
# 1. LOAD DATASET
# =====

df = pd.read_csv("/content/Laptop_price.csv")

print("="*50)
print("5 DATA PERTAMA")
print(df.head())

print("\nINFO DATASET")
print(df.info())

print("\nSTATISTIK DESKRIPTIF")
print(df.describe())

# =====
# 2. EDA
# =====

print("\nJumlah Missing Value:")
print(df.isnull().sum())

# Distribusi Harga
plt.figure(figsize=(8,5))
sns.histplot(df["Price"], kde=True)
plt.title("Distribusi Harga Laptop")
plt.show()
```

Load dataset diperlukan agar proses EDA dapat dilakukan, EDA atau Exploratory Data Analysis itu sendiri adalah sebuah proses analisis sebuah dataset mentah melalui grafik maupun teks yang tertera. Pada kode di atas, analisis data dibantu dengan cara

menampilkan distribusi data dan menampilkan apakah ada missing values atau tidak di dalam dataset.

3.3 Preprocessing Data

a. Label Encoding

```
le = LabelEncoder()

df["Brand"] = le.fit_transform(df["Brand"])
```

Label encoding bertujuan untuk mengubah data kategorikal menjadi data numerik agar bisa diproses oleh komputer dalam program.

b. Standarisasi

```
scaler = StandardScaler()

X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Standarisasi dilakukan agar data yang berjarak jauh nilainya dikecilkan ke dalam suatu range tanpa mengurangi nilai data itu sendiri.

3.4 Pembuatan Grafik Korelasi Fitur

```
plt.figure(figsize=(10,6))

sns.heatmap(
    df.corr(),
    annot=True,
    cmap="coolwarm",
    fmt=".2f"
)

plt.title("Korelasi Antar Fitur")
plt.show()
```

Kode di atas akan membuat sebuah grafik yang akan mempresentasikan seberapa berpengaruh suatu variabel terhadap target prediksi melewati warna.

3.5 Pemiliah label target dan Pembagian data Tes dengan Training

```
# =====
# 5. FEATURE DAN TARGET
# =====

X = df.drop("Price", axis=1)
y = df["Price"]

# =====
# 6. SPLIT DATA
# =====

X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42
)

print("\nJumlah Data Train :", len(X_train))
print("Jumlah Data Test  :", len(X_test))
```

Kode di atas adalah proses dalam memilih label dan yang lainnya sebagai feature, kemudian data tersebut akan dibagi porsi antara testing dan training pada model nanti,

yaitu data yang dipakai untuk testing sebanyak 20% sedangkan data yang lain dipakai sebagai training, penggunaan “random_state=42” juga disengaja karena pola random pada nilai saat 42 mengakibatkan randomizernya akan menghasilkan pola random yang selalu sama sehingga hasil training dan testing akan menjadi konsisten.

3.6 Hyperparameter Tuning

a. Model KNN

```
print("\nMelakukan Tuning KNN...")

knn_param = {
    'n_neighbors': [3,5,7,9,11],
    'weights': ['uniform','distance']
}

grid_knn = GridSearchCV(
    KNeighborsRegressor(),
    knn_param,
    cv=5,
    scoring='r2',
    n_jobs=-1
)

grid_knn.fit(X_train_scaled, y_train)

best_knn = grid_knn.best_estimator_

print("\nBest Parameter KNN")
print(grid_knn.best_params_)
```

Hyper parameter tuning dilakukan untuk mendapatkan hasil terbaik dari proses algoritma dengan cara mengubah nilai pada parameter yang secara langsung memengaruhi rumus. Pada gambar di atas dicoba beberapa kasus dimana nilai k mulai dari 3 hingga 11 dengan nilai “weights” dicoba untuk uniform dan distance, setelah itu setiap kombinasi dilakukan dan dijalankan kodenya dan akan secara otomatis memilih nilai yang paling baik dan memakai model dengan modifikasi tersebut.

b. Model SVR

```
# =====
# 8. HYPERPARAMETER TUNING SVR
# =====

print("\nMelakukan Tuning SVR...")

svr_param = {
    'kernel': ['rbf'],
    'C': [1, 10, 100],
    'gamma': ['scale', 0.1, 0.01]
}

grid_svr = GridSearchCV(
    SVR(),
    svr_param,
    cv=5,
    scoring='r2',
    n_jobs=-1
)

grid_svr.fit(X_train_scaled, y_train)

best_svr = grid_svr.best_estimator_

print("\nBest Parameter SVR")
print(grid_svr.best_params_)
```

Hyperparameter tuning pada algoritma Support Vector Regression dilakukan menggunakan metode “GridSearchCV” untuk mencari kombinasi parameter yang


menghasilkan performa terbaik. Parameter yang dioptimasi meliputi C sebagai parameter regularisasi dengan nilai 1, 10, dan 100 serta gamma sebagai parameter pengontrol pengaruh data terhadap pembentukan model dengan nilai scale, 0,1, dan 0,01. Kernel yang digunakan adalah Radial Basis Function karena mampu menangani hubungan non-linear pada data. Setiap kombinasi parameter diuji menggunakan 5-Fold Cross Validation dan dievaluasi menggunakan R^2 Score. Kombinasi parameter dengan nilai R^2 tertinggi kemudian dipilih secara otomatis sebagai model SVR terbaik untuk digunakan pada tahap prediksi.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Performa Model

a. Grafik



Berdasarkan grafik *Actual vs Predicted* pada model Support Vector Regression (SVR), terlihat bahwa hasil prediksi belum sepenuhnya mengikuti nilai aktual. Pada rentang harga menengah, yaitu sekitar 17.000 hingga 18.500, titik-titik prediksi berada cukup dekat dengan garis ideal sehingga menunjukkan tingkat akurasi yang cukup baik. Namun, pada kelompok harga rendah sekitar 9.000 hingga 12.000, model cenderung menghasilkan prediksi yang lebih tinggi daripada nilai sebenarnya (*overestimate*). Sebaliknya, pada kelompok harga tinggi sekitar 31.000 hingga 33.000, model menghasilkan prediksi yang lebih rendah dari nilai aktual (*underestimate*). Pola ini menunjukkan bahwa SVR memiliki kecenderungan menarik hasil prediksi ke arah nilai rata-rata sehingga kurang mampu menangkap variasi data pada nilai ekstrem. Meskipun demikian, sebaran titik yang relatif rapat menunjukkan bahwa model menghasilkan prediksi yang cukup stabil. Untuk model K-Nearest Neighbor (KNN) Regression, sebagian besar titik data berada sangat dekat dengan

garis ideal. Hal ini menunjukkan bahwa nilai prediksi yang dihasilkan memiliki kesesuaian yang tinggi dengan nilai aktual. Pada kelompok harga tinggi sekitar 31.000 hingga 33.000, hampir seluruh titik berada tepat di sekitar garis diagonal, menandakan tingkat akurasi yang sangat baik. Selain itu, kelompok harga menengah juga mengikuti pola garis ideal dengan cukup baik. Meskipun terdapat beberapa titik yang menyimpang cukup jauh dari garis, terutama pada rentang harga rendah dan menengah, secara keseluruhan KNN mampu mengikuti pola data dengan lebih baik dibandingkan SVR. Hal ini menunjukkan bahwa KNN lebih efektif dalam menangkap hubungan antar data berdasarkan kedekatan karakteristik masing-masing sampel.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil visualisasi performa model menggunakan grafik *Actual vs Predicted*, dapat disimpulkan bahwa model K-Nearest Neighbor (KNN) Regression memiliki performa yang lebih baik dibandingkan Support Vector Regression (SVR) dalam memprediksi harga laptop. KNN menghasilkan titik-titik prediksi yang lebih dekat dengan garis ideal, sehingga menunjukkan tingkat akurasi yang lebih tinggi dan kemampuan yang lebih baik dalam mengikuti pola data aktual. Sementara itu, SVR masih menunjukkan kecenderungan melakukan overestimasi pada harga rendah dan underestimasi pada harga tinggi, yang mengindikasikan adanya kesulitan dalam memprediksi nilai ekstrem. Oleh karena itu, pada dataset yang digunakan dalam penelitian ini, model KNN Regression dapat dianggap sebagai metode yang paling efektif untuk melakukan prediksi harga laptop.